



# Prédictions des mouvements imaginaires de la main

**Eric Béguin  
Bruno Luron  
Philippe Di Piazza**

01/2025

## Table des matières

Introduction.....	2
Dataset .....	4
Méthodes .....	6
Visualisation.....	6
Hypothèse 1.....	8
Prétraitement.....	8
Extraction de caractéristiques.....	8
Modélisation.....	11
Résultats.....	11
Hypothèse 2.....	12
Prétraitement.....	12
Extraction de caractéristiques.....	12
Modélisation.....	12
Résultats.....	13
Hypothèse 3 .....	14
Prétraitement.....	14
Extraction de caractéristiques.....	14
Modélisation.....	14
Résultats.....	15
Discussion.....	15
Conclusion.....	17

Merci à Thomas pour ses conseils et son accompagnement précieux tout au long du projet.

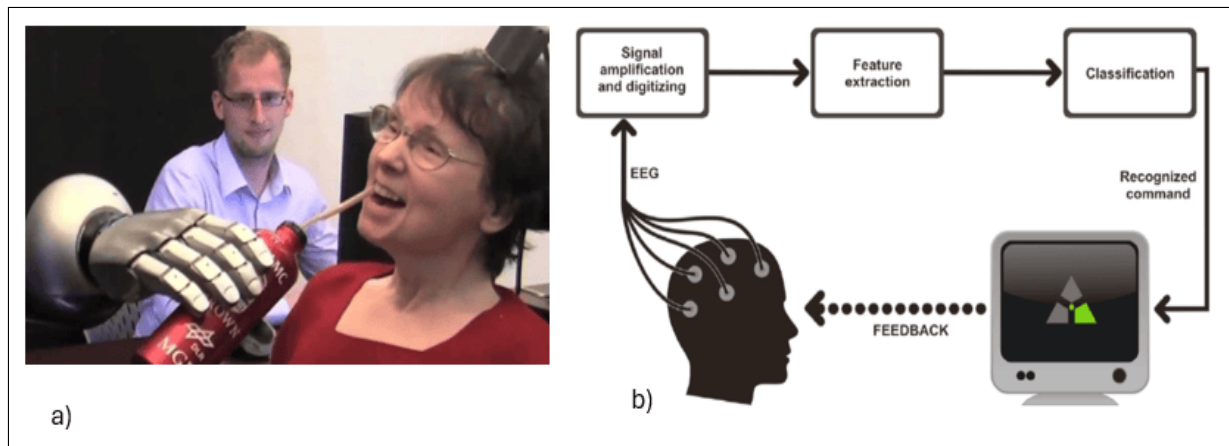
# Introduction

Les interfaces cerveau-ordinateur (BCI) sont des technologies révolutionnaires qui permettent une communication directe entre le cerveau humain et des dispositifs externes. Ce système exploite l'activité cérébrale pour interagir avec des appareils, ouvrant ainsi la voie à des applications innovantes notamment dans la rééducation ou pour les personnes en situation de handicap. Le principe des BCI est d'utiliser les signaux neuronaux pour contrôler ces dispositifs, ce qui requiert une compréhension précise de l'activité cérébrale et de ses différents états (Zhang et al, 2023).

Les découvertes récentes dans ce domaine ont permis d'affiner la compréhension de l'activité neuronale et de son lien avec les ondes cérébrales. Celles-ci jouent un rôle crucial dans les technologies BCI. Les ondes cérébrales sont des oscillations électriques produites par l'activité des neurones dans le cerveau qui peuvent être mesurés grâce à des techniques de neuroimagerie (Électroencéphalographie (EEG), imagerie par résonance magnétique fonctionnelle, magnétoencéphalographie). Elles sont classées en différentes catégories en fonction de leur fréquence. Chaque type d'onde est associé à un état mental ou à une activité cognitive spécifique (Lazarou et al, 2018). En utilisant ce modèle d'activité cérébrale, des phénomènes comme la synchronisation et la désynchronisation des rythmes cérébraux (ERS/ERD) ont pu être observés et ont ouvert de nouvelles perspectives pour l'utilisation des systèmes BCI.

Les études ont montré que les différents comportements humains génèrent des activités cérébrales distinctes, notamment dans le cas de l'imagerie motrice (IM), où des motifs spécifiques apparaissent dans le cortex sensorimoteur. Par exemple, l'imagination de mouvements des membres induit des variations caractéristiques des ondes  $\mu$  (8-13 Hz) et  $\beta$  (14-30 Hz). Les rythmes  $\mu$  augmentent dans l'hémisphère ipsilatéral et diminuent dans l'hémisphère contralatéral, tandis que les rythmes  $\beta$ , impliqués dans des tâches motrices et cognitives, suivent des variations similaires. Ces désynchronisations de l'activité cérébrale, connues sous le nom de désynchronisation événementielle (ERD), reflètent l'intention de mouvement sans exécution physique (Xu et al, 2023). Ces phénomènes sont fondamentaux pour le fonctionnement des systèmes BCI, qui reposent sur l'automatisation de la discrimination de ces motifs.

Ces phénomènes d'ERS et d'ERD permettent de distinguer les intentions motrices du cerveau. Grâce à l'EEG, il est possible de capter ces changements d'oscillations dans les rythmes cérébraux et de les utiliser pour interpréter l'état mental de l'individu. Ces variations des ondes cérébrales deviennent une base pour les systèmes BCI, permettant d'interagir avec des appareils externes (Thomas et al, 2012).



**Figure 1 : Schéma du fonctionnement de système BCI (b) et de leur application, photo du bras automatique BrainGate system (Kingwell, 2012) (a ).**

## Fonctionnement de l'électroencéphalogramme (EEG) : forces et limitations

L'électroencéphalogramme (EEG) est une méthode non invasive qui enregistre les signaux électriques générés par l'activité des neurones corticaux dans les régions superficielles du cerveau. À l'aide d'électrodes placées sur le cuir chevelu, l'EEG détecte les variations de potentiel électrique, offrant une résolution temporelle exceptionnelle. Cela permet de suivre l'activité cérébrale en temps réel, un atout majeur pour les applications nécessitant des réponses rapides, comme les systèmes BCI (Lotte, 2012).

L'un des principaux avantages de l'EEG réside dans sa simplicité, son faible coût et sa sécurité, ce qui le rend accessible pour une utilisation clinique et expérimentale. Ces caractéristiques en font une technique largement utilisée, en particulier dans le domaine des interfaces cerveau-ordinateur (BCI) (Lotte, 2012).

Cependant, l'EEG présente certaines limitations. Sa faible résolution spatiale complique la localisation précise des sources d'activité neuronale, notamment dans les structures cérébrales profondes, car les signaux sont atténués et déformés en traversant les tissus du crâne et du cuir chevelu (Burle et al, 2015). De plus, l'EEG est sensible aux artefacts externes, tels que les mouvements oculaires, les contractions musculaires ou les interférences électromagnétiques, qui peuvent perturber l'enregistrement des signaux d'intérêt.

Enfin, bien que l'EEG soit performant pour détecter l'activité des neurones corticaux, il reste limité pour mesurer l'activité liée à certaines fonctions motrices et cognitives complexes. Ainsi, son efficacité dans les systèmes BCI repose sur des techniques avancées de traitement des signaux et d'interprétation pour surmonter ces défis et améliorer la précision des analyses.

## Problématique : Vers un pipeline robuste et généralisable pour la classification des ondes cérébrales

Malgré les avancées des systèmes BCI basés sur l'IM, classifier efficacement les signaux EEG reste un défi de taille. L'un des principaux obstacles est la variabilité inter-expérimentale, qui limite la capacité des modèles à généraliser d'un individu à un autre. Cela pose la question cruciale de comment construire une pipeline robuste, allant du prétraitement des signaux à leur classification, pour améliorer cette généralité (Huang et al, 2023).

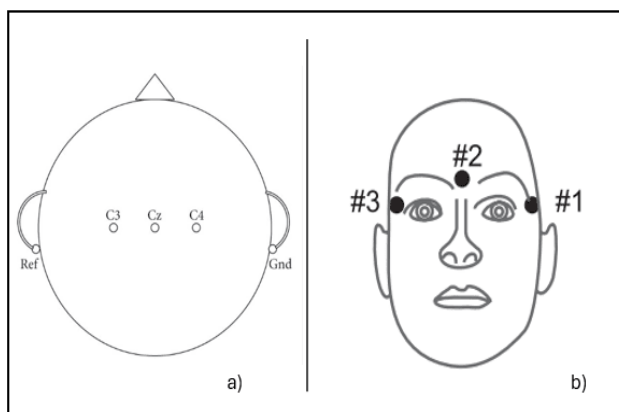
Pour y parvenir, il est essentiel d'explorer des approches méthodologiques permettant de mieux capturer la richesse des signaux tout en minimisant les impacts du bruit et des artefacts. Répliquer des expériences sur différents sujets et divers contextes pourrait également offrir des perspectives intéressantes pour rendre les modèles plus adaptable.

## Dataset

Nous avons utilisé la base de données 'BCI Competition IV Dataset b', qui comprend des données EEG provenant de 9 sujets. Elles répondent bien à notre problématique car chaque sujet a participé à 5 sessions, comprenant différentes conditions expérimentales. Les deux premières contiennent des données d'entraînement sans retour d'information (screening), et les trois dernières ont été enregistrées avec retour d'information (neurofeedback(nf)).

Les enregistrements EEG ont été effectués à l'aide de trois dérivations bipolaires (C3, Cz et C4) avec une fréquence d'échantillonnage de 250 Hz. Les signaux ont été filtrés dans une bande de fréquence comprise entre 0,5 Hz et 100 Hz, incluant un filtre coupe-bande à 50 Hz. La position des électrodes variait légèrement d'un sujet à l'autre.

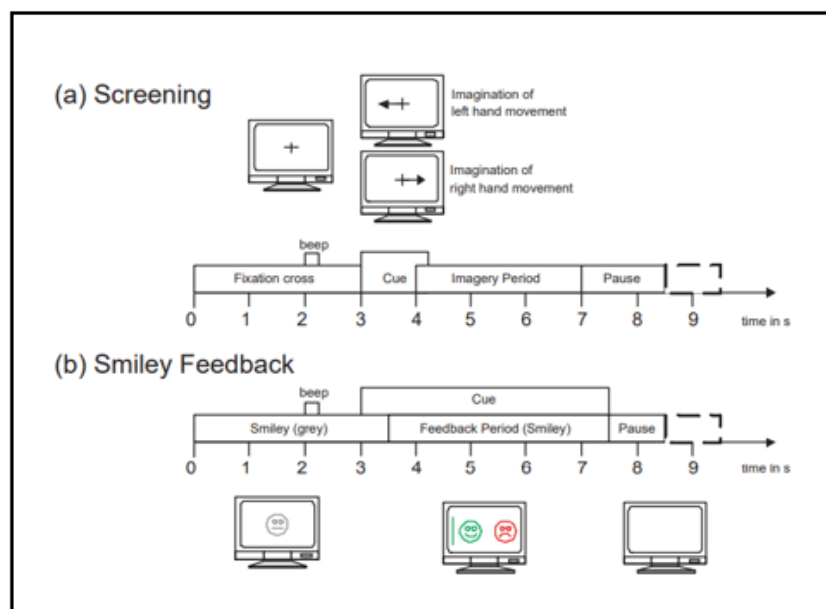
En plus des canaux EEG, l'électro-oculogramme (EOG) a été enregistré avec trois électrodes monopolaires (le mastoïde gauche servant de référence), en utilisant les mêmes réglages d'amplificateur.



**Figure 2 : Configuration des électrodes de l'électroencéphalogramme (a), et de l'électrooculogramme (b).**

Le paradigme de screening basé sur des indices comporte deux classes : l'imagerie motrice (IM) de la main gauche (classe 1) et de la main droite (classe 2). Les sujets ont réalisé deux sessions, organisées à deux jours différents sur une période de deux semaines, avec 120 répétitions par classe par session. Chaque essai débutait par une croix de fixation accompagnée d'un bref signal sonore. Après quelques secondes, un indice visuel, représenté par une flèche pointant à gauche ou à droite selon la classe, apparaissait pendant 1,25 seconde. Les sujets devaient alors imaginer le mouvement correspondant pendant 4 secondes. Une pause minimale de 1,5 seconde suivait chaque essai, avec un délai aléatoire additionnel pouvant atteindre 1 seconde pour éviter toute prévisibilité.

Lors des trois sessions nf, 120 essais par classe d'imagerie motrice (IM) ont été enregistrés avec un retour visuel sous forme de smiley. Chaque essai commençait par un smiley gris centré à l'écran (seconde 0), suivi d'un bip d'avertissement à la seconde 2. Entre la troisième et la septième seconde, un indice visuel indiquait au sujet d'imaginer un mouvement de la main gauche ou droite pour déplacer le smiley dans la direction correspondante. Le smiley devenait vert si le mouvement était correct, rouge sinon. La distance et l'expression du smiley (heureux ou triste) reflétaient la sortie du classificateur. À la fin de l'essai, l'écran devient vide pendant 1 seconde plus intervalle aléatoire avant le début du cycle suivant.



**Figure 3 : Organisation des séances 1,2 de screening (a) et de la séance 3 avec le retour image (Nf) (b).**

Nous utiliserons seulement les deux sessions de screening et une session nf, car les deux dernières sessions de nf ne contiennent pas les informations sur la direction (gauche ou droite) de l'IM. Cette structure nous permet d'évaluer la précision et la généralisabilité de nos pipelines dans des conditions variées, incluant les dimensions intra-expérimentales.

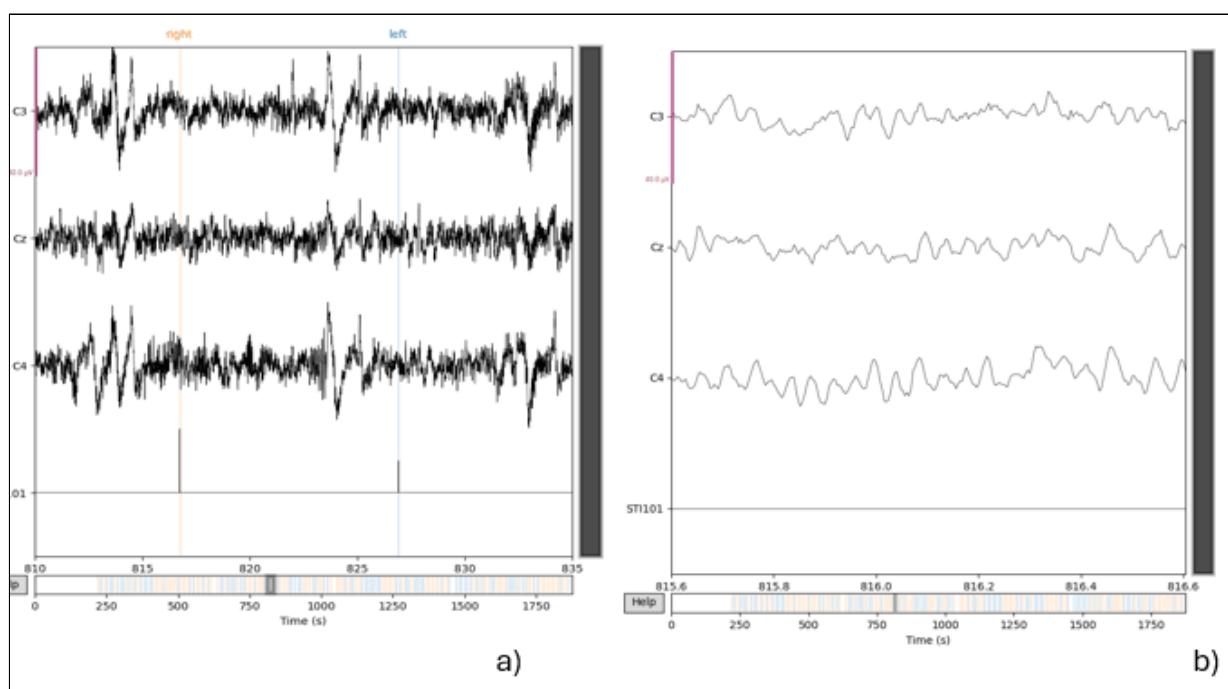
# Méthodes

Pour répondre à notre problématique, nous avons formulé trois hypothèses basées sur des méthodologies variées, s'appuyant principalement sur des principes neuroscientifiques ou statistiques.


Les données brutes provenaient de sessions d'enregistrement EEG, qui sont complexes à traiter. Ainsi, le prétraitement des données et l'utilisation de techniques de visualisation ont varié en fonction de l'hypothèse testée.

## Visualisation

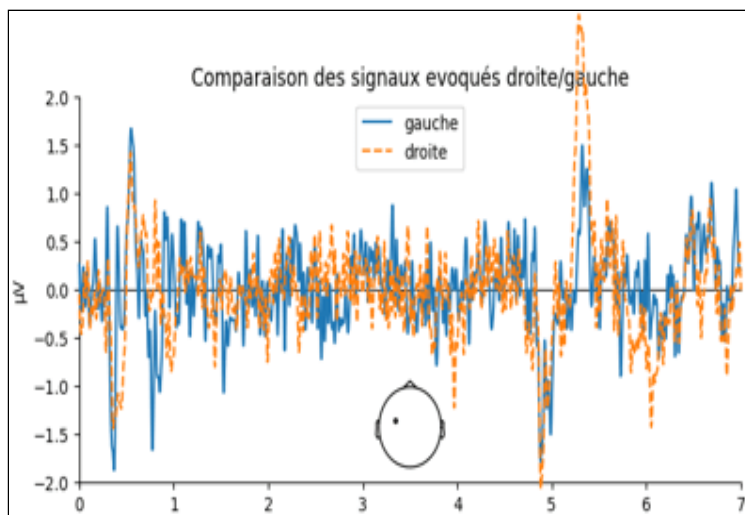
Nous utilisons la librairie [MNE](#) afin de visualiser les données. Pour cela, nous créons un dataframe qui regroupe les informations de signal et de classe. Nous pourrions ainsi visualiser ces deux informations sur un même graphique. Nous réalisons le découpage en époques grâce à la fonction dédiée. Nous réalisons cette exploration sur plusieurs fichiers, et sur différentes échelles de temps afin d'évaluer la qualité des enregistrements et d'envisager les différentes étapes de pré-processing nécessaires à l'exploitation de ces données brutes.



EEG brut sur 35 secondes (a) et sur 1 seconde (b). Dans le signal (a) on observe l'activité cérébrale de deux epochs : un de l'IM gauche, un de l'IM droite.




**Puissance du signal brut sur l'ensemble d'un run**



**Comparaison des signaux évoqués lors des tentatives gauche/droite**

[MNE](#) dispose d'une fonctionnalité de calcul de de signaux évoqués. Il s'agit de regrouper les signaux correspondant à une modalité et d'en faire la moyenne afin d'obtenir une vue moyenne du signal sur un type de tentatives.

Une étape commune du prétraitement est le filtrage du signal : après plusieurs tentatives et les informations recueillies, nous décidons d'appliquer un filtre passe bande 1Hz-30Hz.



**Données EEG avant (a) et après (b) filtrage, on observe des signaux plus nets.**



## Hypothèse 1

L'hypothèse 1 explore l'utilisation des techniques bien établies dans la recherche neuroscientifique. L'objectif est de tirer parti des informations spatio-temporelles et fréquentielles contenues dans les signaux cérébraux afin de reconnaître les schémas neuronaux associés à cette activité mentale. Nous nous appuyons sur des approches courantes, telles que l'analyse des spectres de densité de puissance, l'identification des rythmes sensorimoteurs (notamment  $\mu$  et  $\beta$ ), et des outils de filtrage spatial comme les filtres Common Spatial Patterns (CSP).


## Prétraitement

Pour le prétraitement des signaux EEG, nous avons appliqué un filtre passe-bande entre 8 et 30 Hz, afin de nous concentrer sur les rythmes alpha ( $\mu$ ) et bêta. L'ICA (analyse en composantes indépendantes, prétraitement classique de l'EEG) n'a pas été possible en raison du nombre limité de canaux EEG. Nous avons donc utilisé une régression basée sur les signaux EOG pour réduire les artefacts oculaires, comme ceux dus aux mouvements des yeux et clignements. Une correction de la ligne de base a été effectuée en prenant une période de 0,2 seconde avant chaque epoch. La valeur moyenne des signaux pendant les 0.2s est déduite afin de compenser les variations lentes non liées à l'activité cérébrale d'intérêt.

## Extraction de caractéristiques


Dans l'extraction de caractéristiques, nous avons utilisé l'approche de Blankertz et al. (2007) qui utilise l'application de filtres CSP. Cette méthode permet de maximiser la séparation entre les classes d'intérêt, notamment celles associées à l'imagerie motrice, en extrayant des patterns spatiaux spécifiques à chaque classe. Nous avons ensuite appliqué la technique du logarithmic variance (log-var) pour transformer les signaux CSP en valeurs plus distinctes et comparables. Cette procédure a été réalisée sur plusieurs observations pendant la phase de visualisation.

Nous avons appliqué les filtres CSP sur les epochs EEG, projetant les données dans un espace où les différences de variance entre les classes sont maximisées, facilitant l'extraction des composantes discriminantes. Après cela, nous avons calculé la variance de chaque composante filtrée et appliqué le logarithme de cette variance pour normaliser les valeurs et atténuer l'impact des grandes variations, afin d'obtenir des caractéristiques adaptées à la classification des intentions motrices.



**Figure 5 : Signal EEG filtré CSP pour C3, Cz, et C4 avec en bleu event\_0 (IM main gauche), et en rouge event\_1 (IM main droite)**

Nous avons également appliqué ce processus aux Power Spectral Densities (PSD). Pour chaque epoch EEG, nous avons d'abord calculé la PSD, puis utilisé les filtres CSP pour extraire les composantes discriminantes, avant de calculer le logarithme de la variance de ces composantes. Cela permet d'extraire des caractéristiques basées sur la puissance spectrale plutôt que sur l'activité brute du signal.



**Figure 6 : Signal de densité spectrale de puissance filtré CSP de IM gauche (gauche) et im droite (droite) on voit que les PSD des canaux vert et bleu s'échangent en fonction de l'événement**

Enfin, nous avons appliqué la pipeline sur l'amplitude par le temps (amp by time), qui analyse l'évolution de l'intensité du signal EEG au fil du temps. Contrairement à la PSD, qui examine la distribution de l'énergie dans le domaine des fréquences, l'amplitude par le temps capture les variations temporelles de l'intensité du signal. Nous avons concentré notre analyse sur la bande beta, car elle présente les différences les plus marquées lors de la phase de visualisation.

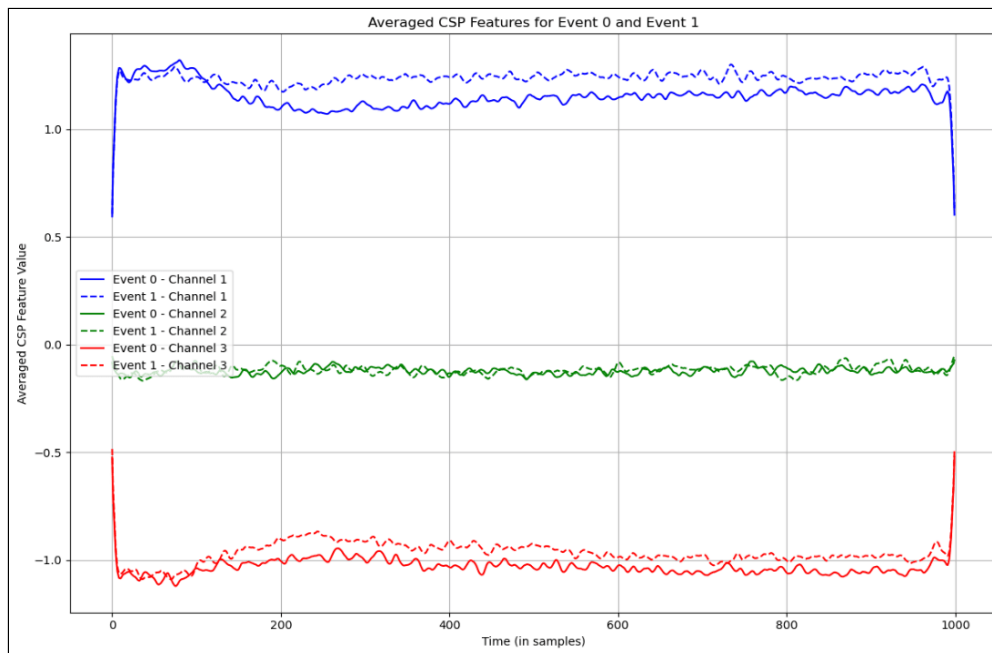


Figure 7 : amp by time des 3 canaux en fonction de l'IM (ligne pleine, IM gauche et pointillée IM droite)

Pour les trois facteurs (CSP, PSD et amplitude par le temps), nous avons extrait trois composantes distinctes, permettant de capturer des caractéristiques discriminantes pour la classification des intentions motrices.

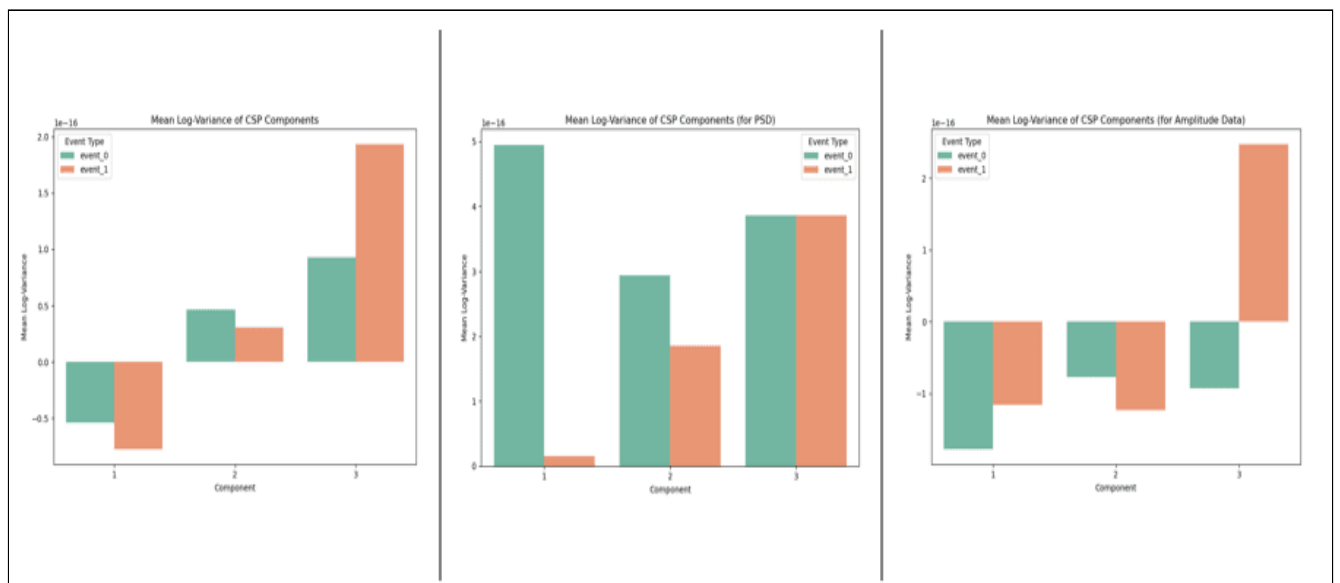


Figure 8 : log var des CSP du signal brut, des PSD et de l'amp by time, moyenné par IM gauche (bleu) et droite (orange)

## Modélisation


Dans ce processus, nous avons utilisé trois modèles de classification distincts, chacun appliqué à des ensembles de caractéristiques extraites des signaux EEG. Ces modèles sont : un Random Forest, un SVM (Support Vector Machine) et un AdaBoost.

Nous avons aussi utilisé un réseau de neurones convolutionnels (CNN) pour classer les signaux EEG en fonction des caractéristiques extraites. Il comprend deux couches de convolution 1D pour extraire les caractéristiques des signaux, suivies d'une couche de Flatten pour aplatir les données et de couches densément connectées pour apprendre des représentations plus complexes. Une couche de Dropout est ajoutée pour éviter le surapprentissage. L'optimiseur Adam et la fonction de perte binary crossentropy sont utilisés pour l'entraînement. Un mécanisme d'early stopping arrête l'entraînement si la performance de validation ne s'améliore pas après un certain nombre d'époques.

Chaque modèle a été testé sur différentes combinaisons de caractéristiques et a été appliqué à trois situations spécifiques:

Nous avons appliqué les modèles sur l'ensemble des epochs disponibles, afin de capturer une vue d'ensemble complète des intentions motrices à travers toutes les données EEG. Par la suite, les modèles ont été ajustés en fonction des epochs utilisées lors des premières sessions de screening, puis de NF. Pour chaque condition expérimentale, les modèles ont été optimisés afin d'obtenir la meilleure précision possible.

## Résultats



**Figure 9 : Accuracy des différents modèles en fonction du type de modèle et des condition expérimentales**

Pour chaque modèle, la phase d'entraînement a été réalisée sur 80 % des données, tandis que les 20 % restants ont été utilisés pour les tests. Cette répartition a été effectuée de manière aléatoire. Les résultats obtenus montrent des performances satisfaisantes, avec une précision dépassant 70 % pour

les tests du DNN sur l'ensemble des epochs et lors de la phase de neurofeedback. Cependant, une baisse significative des performances a été observée lors des tests sur la phase de screening.

Les implications de ces résultats seront abordées en détail dans la section discussion, où nous examinerons les raisons possibles de ces variations de performance. La suite des hypothèses tient compte de ces résultats positifs notamment pour la session NF.

## Hypothèse 2

Dans cette partie nous nous intéresserons principalement aux enregistrements des runs3. C'est-à-dire les enregistrements NF pour lesquels nous disposons du résultat de classification. Nous constatons que le changement de protocole expérimental et la répétition des sessions induit un changement influençant la structure des données enregistrées. Nous ne nous intéresserons qu'aux données EEG. Nous choisissons ce type de sessions pour lesquelles nous disposons de la classe afin de nous ramener à un cas de classification supervisée.

## Prétraitement

On applique une baseline de -0.2s. La valeur moyenne des signaux pendant les 0.2s précédant le début de l'époque est déduite. Cette valeur a été retenue suite à différentes tentatives.

Afin d'atténuer l'effet du bruit, une pratique courante consiste à changer la référence du signal. C'est-à-dire de prendre un des signaux de le considérer comme une base pour les autres. Souvent le signal choisi correspond à une électrode placée dans la zone médiane du crâne. Dans notre cas, le signal Cz nous semble un bon candidat. Nous effectuons donc ce changement de référence grâce à la fonction de [MNE](#) correspondante.

L'exploration des différentes valeurs de signal, pour les différents candidats montre des disparités d'intensités assez importantes. Pour tenter de les corriger, nous avons appliqué une mise à l'échelle de type MinMax.

## Extraction de caractéristiques

Nous nous plaçons dans un espace Fréquence/Temps grâce au calcul TFR (revient à calculer le PSD en gardant la notion de temporalité). L'analyse des données nous incite à retenir les fréquences de la gamme alpha. On s'intéressera à la différence entre C3 et C4.

## Modélisation

Le jeu d'entraînement est constitué par les enregistrements des candidats 1 à 7, le jeu de test par ceux des candidats 8 et 9, ce choix est fait de façon arbitraire.

Nous entraînons différents modèles, LogisticRegression, AdaBoostClassifier, SVM sur le jeu de données. A la vue des premiers résultats SVM ne semble pas adapté. Afin d'améliorer les performances, nous modifions les paramètres max\_iter pour LogisticRegression et faisons un GridSearch sur AdaBoostClassifier. Nous effectuons également des entraînements sur une fenêtre

temporelle glissante sur chaque époque. Ensuite nous essayons de réduire les fréquences utilisées.

## Résultats

LogisticRegression score: 0.80625

classe	précision	recall	f1-score
1	0.89	0.70	0.78
2	0.75	0.91	0.82


AdaBoostClassifier score: 0.790625

classe	précision	recall	f1-score
1	0.87	0.69	0.77
2	0.74	0.89	0.81

RandomForestClassifier score: 0.803125

classe	précision	recall	f1-score
1	0.86	0.72	0.79
2	0.76	0.88	0.82

Les meilleurs résultats sont obtenus sur la plage de fréquences 10.5 - 12.5Hz et sur l'intervalle 1s - 3s



**Figure PSD entre 1 et 3 secondes sur la plage de fréquence 10.5 - 12.5Hz. Une différence nette entre le PSD de l'IM main gauche et droite est observable notamment pour les canaux C3 et C4.**

## Hypothèse 3

### Prétraitement

Dans cette partie, nous nous intéresserons principalement aux enregistrements des sessions 3. C'est-à-dire les enregistrements pour lesquels nous disposons du résultat de classification. Nous constatons que le changement de protocole expérimental et la répétition des sessions induit un changement influençant la structure des données enregistrées. Nous ne nous intéresserons qu'aux données EEG (les données ECG sont ignorées).

Le but de la méthode est de déterminer les meilleurs critères de segmentation du signal (c.-à-d. définir la meilleure fenêtre associée à un type d'algorithme de classification et une typologie d'extraction de caractéristique).

### Extraction de caractéristiques

Le signal brut est décomposé en époque correspondant aux différentes tentatives. Nous appliquons une décomposition en ondelettes de « Daubechies », sur la différence des échantillons entre les électrodes C4 et C3. Cela permet d'analyser les fréquences caractéristiques tout en conservant des informations temporelles et réduire la dimensionnalité des données, facilitant ainsi leur interprétation et leur traitement par les algorithmes de classification.


### Modélisation

Le jeu de d'entraînement est composé de la session 3 de 7 candidats tirés au hasard parmi les 9 participants. Le jeu de test / validation est, quant à lui, composé des « runs » 1 et 2 des 2 participants qui n'ont pas été retenus dans le jeu d'entraînement.

Une variété de modèles d'apprentissage automatique a été utilisée pour classer les IM, parmi lesquels le SVM (Support Vector Machine), la régression logistique, l'analyse discriminante linéaire, et des méthodes avancées comme le « Gradient Boosting » ou les k-plus-proches voisins (k-NN) ou encore l'analyse en discriminant linéaire « DAL ». Ces approches, combinées à des stratégies de segmentation, ont permis d'améliorer la précision et la fiabilité des prédictions.

## Résultats

Pour les graphiques présentés ci-dessous, en abscisse sont représentés le temps de départ et de fin de la segmentation après le top départ de l'événement ("EventStart"), en nombre d'échantillons (la fréquence d'échantillonnage est de 250 Hz). Et, en ordonné le ratio obtenu.



Les meilleurs résultats sont obtenus pour le model de classification DAL.

Nous obtenons un score de prédiction de 71% pour une la fenêtre 75-225 (à 300 milliseconde après le début de l'évènement pour se terminer 900 milliseconde après de début de l'évènement, soit une fenêtre d'environ 600 milliseconde)

## Discussion

Nos modèles ont montré des résultats prometteurs, atteignant une précision de 80 % sur les données NF et 73 % sur l'ensemble des données. Ces performances illustrent une intégration réussie des concepts fondamentaux de la recherche en interface cerveau-machine (BCI). En nous



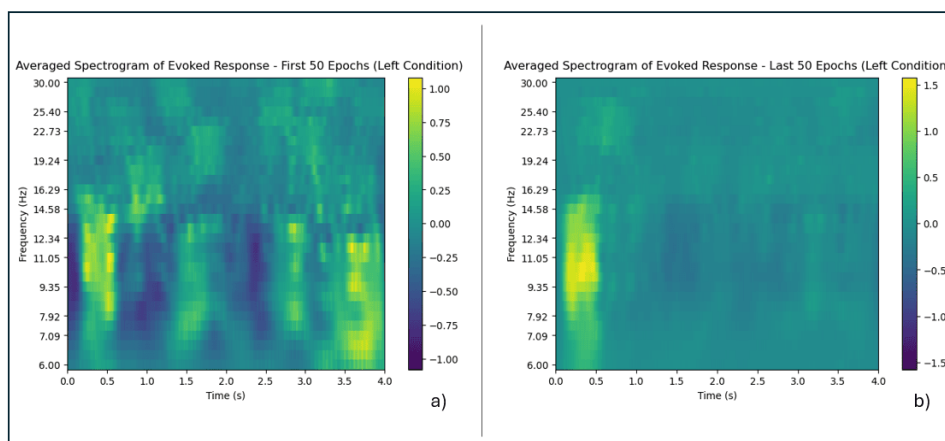
concentrant sur les rythmes mu et beta, essentiels pour l'imagerie motrice (IM), nous avons extrait des caractéristiques différenciables, permettant ainsi une classification efficace des états cognitifs.

Ces observations s'accordent avec les travaux de Giromini (2010), qui a identifié une désynchronisation des rythmes mu (ERD) lors de l'IM, ainsi qu'avec ceux de McFarlan (2000), qui a démontré que les mouvements réels et imaginés induisent une désynchronisation des rythmes mu et beta, particulièrement dans la région centrale droite du cerveau. Par ailleurs, les recherches de Yu et al. (2022) ont confirmé l'importance de ces rythmes pour la conception de classificateurs précis, soulignant leur pertinence dans l'analyse et la classification des signaux EEG dans des applications BCI.

Une autre différence majeure observée réside dans l'écart de précision entre les sessions de screening et celles de NF, respectivement de 63 % contre 80 %. Cette disparité peut être expliquée par l'importance du retour d'information visuel en temps réel, qui joue un rôle crucial dans l'amélioration des performances en BCI. Ce constat est également appuyé par la littérature, où il a été démontré que les compétences en IM acquises grâce à l'utilisation d'une BCI avec des retours visuels dynamiques sont plus robustes (Alimardani et al., 2016). En effet, un retour visuel adapté peut rendre la technologie BCI plus facile à utiliser, plus efficace et accessible à un plus grand nombre d'utilisateurs en réduisant les distractions (Fodor et al., 2024).

Cependant, la littérature sur ce sujet est contrastée. Par exemple, Vasilyev (2021) a montré que le feedback visuel en temps réel n'augmente pas les ERD par rapport à l'absence de feedback. Il convient de noter que cette étude s'est déroulée sur plusieurs mois, mettant en évidence l'importance de l'entraînement personnalisé à la tâche d'imagerie motrice (IM) et à l'utilisation de la BCI. En effet, le fonctionnement d'une BCI n'est pas intuitif, et les utilisateurs doivent apprendre à contrôler volontairement leurs activités neuronales. Pour les BCIs basées sur l'IM, une période d'entraînement relativement longue est nécessaire avant que les utilisateurs ne maîtrisent la tâche et atteignent des performances optimales (Alimardani et al., 2016).

Dans notre étude, les sessions de screening correspondent aux deux premières sessions, tandis que pour la session de neurofeedback (NF), les participants sont déjà entraînés, ce qui peut être considéré comme un entraînement préalable. Ce facteur pourrait expliquer la différence notable observée dans nos modèles.



Ce phénomène est observable en comparant les spectrogrammes des réponses évoquées (evoked) **des 50 premiers événements d'imagerie motrice (IM) (a) de la main gauche avec ceux des 50 derniers (b)**. Sur le spectrogramme (b), on observe que l'activation est beaucoup moins répandue et

plus précise, ce qui pourrait indiquer une habitude à la tâche et un apprentissage, contrairement à l'effort plus prolongé observé dans le spectrogramme (a).

Nos résultats ont également mis en évidence l'importance cruciale de la plage de temps sélectionnée pour extraire les caractéristiques. En effet, nous avons obtenu de meilleurs résultats en utilisant une plage de temps qui prend en compte le temps de réaction au stimulus et qui est plus courte que l'intégralité de l'époque. Ce constat est en accord avec la littérature, qui montre que des fenêtres temporelles plus courtes, centrées sur les moments clés de l'activité neuronale (comme le temps de réaction ou les phases initiales après un stimulus), permettent de capturer des informations pertinentes tout en réduisant le bruit. Par exemple, des études ont démontré que des époques d'environ 1 à 2 secondes suffisent pour analyser efficacement les fréquences pertinentes tout en optimisant la précision des classificateurs en BCI (Blankertz et al, 2007).

En incluant tous ces facteurs dans notre pipeline, nous avons obtenu des résultats encourageants sur le jeu de données fourni. Cependant, une question demeure : nos modèles sont-ils exploitables dans un usage courant et sur des données inconnues ? En effet, nos données reposent sur seulement 9 participants, et compte tenu de la sensibilité des signaux EEG, il est légitime de s'interroger sur la généralisabilité de notre paradigme.

Ce point fait l'objet de la partie exploitation d'un modèle de notre démonstration [streamlit](#). Dans cette partie, nous tenterons d'interagir avec un de nos modèles pré entraîné pour lui faire suivre un chemin. N'ayant pas de matériel d'enregistrement d'EEG à notre disposition nous utiliserons des enregistrements issus du jeu de données fourni mais n'ayant pas participé à son entraînement.

## Conclusion

Nos résultats montrent des taux d'accuracy encourageants et comparable aux standards de la littérature (Chen et al, 2021). Ces résultats soulignent le potentiel des approches utilisées pour la classification de l'imagerie motrice dans le cadre des interfaces cerveau-ordinateur (BCI).

Cependant, notre étude met également en évidence l'importance cruciale des conditions expérimentales lors de la collecte des données EEG. En particulier, les performances ont été significativement réduites lorsque les sessions expérimentales étaient trop longues ou lorsque les participants ne recevaient pas de feedback en temps réel. Ces facteurs soulignent la nécessité d'un contrôle strict des conditions pour minimiser les effets du bruit dans les signaux EEG et maximiser la qualité des données.

Enfin, bien que nos résultats soient prometteurs, ils révèlent également les limites inhérentes à l'EEG, notamment en ce qui concerne la sensibilité au bruit et les artefacts. Les travaux futurs devraient explorer la combinaison de conditions expérimentales optimales pour améliorer la généralisation des caractéristiques extraites et, par conséquent, la précision des classifications. Cette approche pourrait contribuer à des avancées significatives dans le développement de BCI plus performantes et robustes.

## Références

- Alimardani, M., Nishio, S., & Ishiguro, H. (2016). The importance of visual feedback design in BCIs: A study of brain activity during motor imagery training. *Brain-Computer Interfaces*, 3(3), 141–152. <https://doi.org/10.1080/2326263X.2016.1231037>
- Blankertz, B., Tomioka, R., Lemm, S., Kawanabe, M., & Müller, K. R. (2007). Optimizing spatial filters for robust EEG single-trial analysis. *IEEE Signal Processing Magazine*, 25(1), 41–56. <https://doi.org/10.1109/MSP.2007.4436578>
- Chen Z, Wang Y, Song Z. Classification of Motor Imagery Electroencephalography Signals Based on Image Processing Method. *Sensors* (Basel). 2021 Jul 7;21(14):4646. doi: 10.3390/s21144646. PMID: 34300386; PMCID: PMC8309641.
- Fodor, M. A., Herschel, H., Cantürk, A., Heisenberg, G., & Volosyak, I. (2024). Evaluation of Different Visual Feedback Methods for Brain-Computer Interfaces (BCI) Based on Code-Modulated Visual Evoked Potentials (cVEP). *Brain Sci*, 14(8), 846. <https://doi.org/10.3390/brainsci14080846>
- Giromini, L., Porcelli, P., Viglione, D.J., Parolin, L., & Pineda, J.A. (2010). The feeling of movement: EEG evidence for mirroring activity during the observations of static, ambiguous stimuli in the Rorschach cards. *Biological Psychology*, 85, 233–241. <https://doi.org/10.1016/j.biopsycho.2010.07.008>
- Huang, G., Zhao, Z., Zhang, S., Hu, Z., Fan, J., Fu, M., Chen, J., Xiao, Y., Wang, J., & Dan, G. (2023). Discrepancy between inter- and intra-subject variability in EEG-based motor imagery brain-computer interface: Evidence from multiple perspectives. *Frontiers in Neuroscience*, 17, 1122661. <https://doi.org/10.3389/fnins.2023.1122661>
- Kingwell, K. (2012). Neurally controlled robotic arm enables tetraplegic patient to drink coffee of her own volition. *Nature Reviews Neurology*, 8, 353. <https://doi.org/10.1038/nrneurol.2012.101>
- Lazarou, I., Nikolopoulos, S., Petrantonakis, P. C., Kompatsiaris, I., & Tsolaki, M. (2018). EEG-based brain-computer interfaces for communication and rehabilitation of people with motor impairment: A novel approach of the 21st century. *Frontiers in Human Neuroscience*, 12, 14. <https://doi.org/10.3389/fnhum.2018.00014>
- Leeb, R., Brunner, C., Müller-Putz, G. R., Schlögl, A., & Pfurtscheller, G. (2008). BCI Competition 2008 Graz data set B. Proceedings of the 4th International Brain-Computer Interface Workshop and Training Course, 79-84. Graz University of Technology, Austria.
- Fabien Lotte. Les Interfaces Cerveau-Ordinateur: Conception et Utilisation en Réalité Virtuelle. *Revue des Sciences et Technologies de l'Information - Série TSI : Technique et Science Informatiques*, 2012, 31 (3), pp.289-310. fffhal-00659822v2f
- McFarland, D. J., Miner, L. A., Vaughan, T. M., & Wolpaw, J. R. (2000). Mu and beta rhythm topographies during motor imagery and actual movements. *Brain Topography*, 12(3), 177–186. <https://doi.org/10.1023/a:1023437823106>
- Thomas, E., Fruitet, J., & Clerc, M. (2012). Investigating brief motor imagery for an ERD/ERS based BCI. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, 2012,

2929–2932. <https://doi.org/10.1109/EMBC.2012.6346577>

Vasilyev, A. N., Nuzhdin, Y. O., & Kaplan, A. Y. (2021). Does real-time feedback affect sensorimotor EEG patterns in routine motor imagery practice? *Brain Sciences*, 11(9), 1234. <https://doi.org/10.3390/brainsci11091234>

Xu, X., Lee, D., Drougard, N., et al. (2023). Signature methods for brain-computer interfaces. *Scientific Reports*, 13, 21367. <https://doi.org/10.1038/s41598-023-41326-8>

Yu, T., Kober, S. E., & Neuper, C. (2022). Advanced classifiers for motor imagery in brain-computer interfaces: A comprehensive review. *Frontiers in Computational Neuroscience*, 16, Article 876543. <https://doi.org/10.3389/fncom.2022.876543>

Zhang, J., Li, J., Huang, Z., Huang, D., Yu, H., & Li, Z. (2023). Recent progress in wearable brain-computer interface (BCI) devices based on electroencephalogram (EEG) for medical applications: A review. *Health Data Science*, 3, 0096. <https://doi.org/10.34133/hds.0096>